1

# O Processo de Ciência de Dados e os Principais Pacotes

Linguagem Python

*Python Open Data Science Stack*

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

2

# Etapas de um Projeto em Ciência de Dados

- Problema de Negócio
  - Identificação do problema a ser resolvido.
  - Formulação das perguntas corretas

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).



# Etapas de um Projeto em Ciência de Dados

- Problema de Negócio
  - Identificação do problema a ser resolvido.
  - Formulação das perguntas corretas
- Aquisição dos Dados
  - Importação, Dados Estruturados e não-estruturados, Diversas fontes...

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

# Etapas de um Projeto em Ciência de Dados

- Problema de Negócio
  - Identificação do problema a ser resolvido.
  - Formulação das perguntas corretas
- Aquisição dos Dados
  - Importação, Dados Estruturados e não-estruturados, Diversas fontes...
- Exploração dos Dados
  - Entender os dados, limpá-los, transformá-los... Aplicação de diversas técnicas de análise dos dados.

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

5

# Etapas de um Projeto em Ciência de Dados

- Problema de Negócio
  - Identificação do problema a ser resolvido.
  - Formulação das perguntas corretas
- Aquisição dos Dados
  - Importação, Dados Estruturados e não-estruturados, Diversas fontes...
- Exploração dos Dados
  - Entender os dados, limpá-los, transformá-los... Aplicação de diversas técnicas de análise dos dados.
- Análise: Descritiva, Diagnóstica, Preditiva e Prescritiva.
  - Relatórios, Insights, Modelos etc.
  - Apresentação dos Resultados

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

6

# Etapas de um Projeto em Ciência de Dados

- Problema de Negócio
  - Identificação do problema a ser resolvido.
  - Formulação das perguntas corretas
- Aquisição dos Dados
  - Importação, Dados Estruturados e não-estruturados, Diversas fontes...
- Exploração dos Dados
  - Entender os dados, limpá-los, transformá-los... Aplicação de diversas técnicas de análise dos dados.
- Análise: Descritiva, Diagnóstica, Preditiva e Prescritiva.
  - Relatórios, Insights, Modelos etc.
  - Apresentação dos Resultados

Automatizar o Processo
DEPLOY DO MODELO

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).



# Estudos de Caso...

kaggle.com

kaggle

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

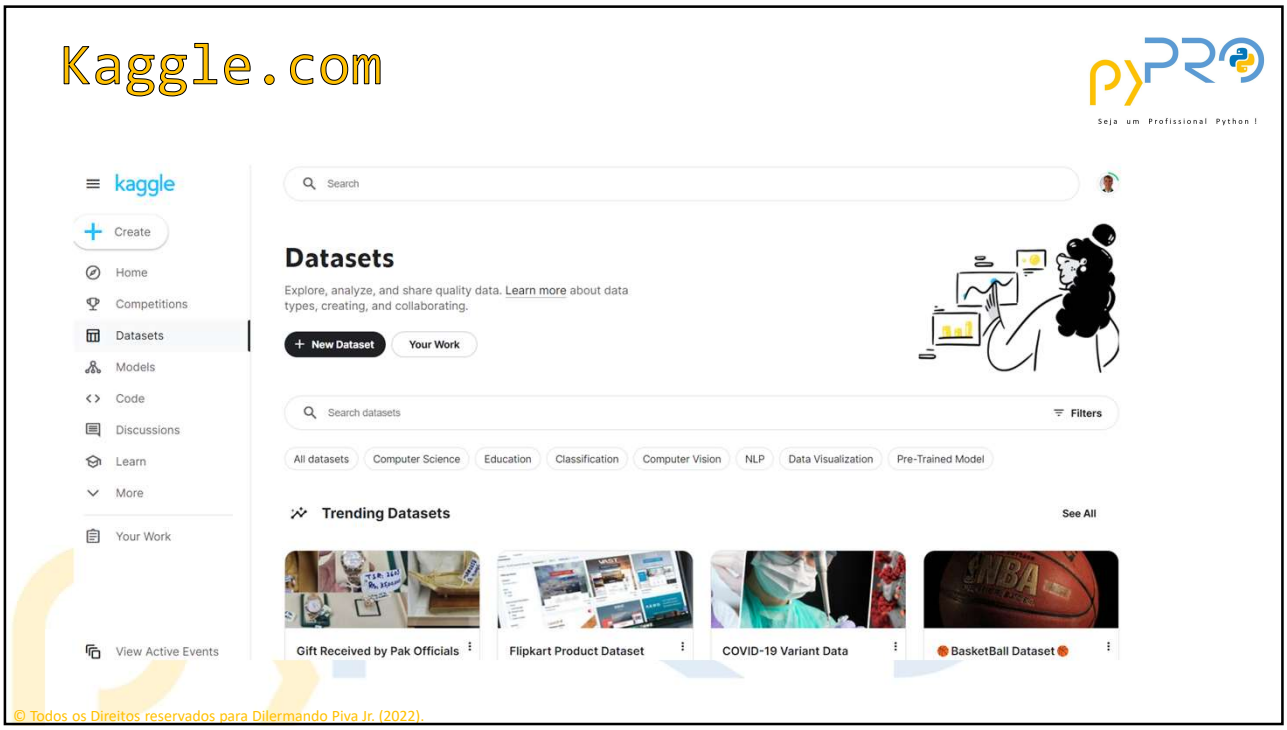


© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

# Estudo de Caso

Credit Score

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

11

Seja um Profissional Python !

12

# Os Principais Pacotes

Linguagem Python

*Python Open Data Science Stack*

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

13

## PODSS x Outras Ferramentas

- Outras Ferramentas
  - Existe uma infinidade de ferramentas destinadas a Análise e Ciência de Dados...
    - Linguagem R, SAS, Ms-PowerBI, Tableau, Matlab...
- Neste curso, vamos trabalhar apenas com Linguagem Python e Pacotes/Bibliotecas livres de análise de Dados
  - Pilha (Conjunto de Ferramentas Hierarquizada) Livres para Ciência de Dados em Python
  - Python Open Data Science Stack

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

14

# Qual linguagem utilizar?

## Em Ciência de Dados

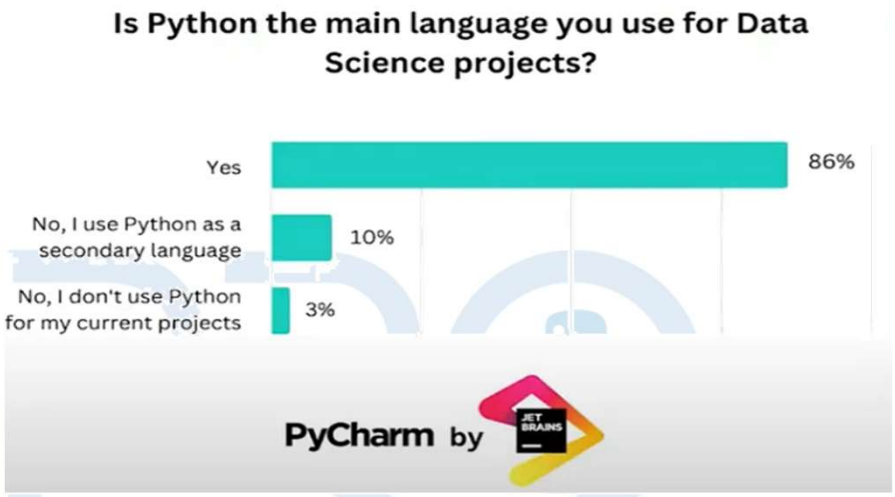


Fonte: https://blog.jetbrains.com/pycharm/2023/10/future-of-data-science/

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).



# Python Open D. S. Stack

python™ IP[y]: IPython jupyter

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

# Python Open D. S. Stack

pyPRO
Seja um Profissional Python !

NumPy SciPy matplotlib

python™ IP[y]: IPython jupyter

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

17

# Python Open D. S. Stack

pyPRO
Seja um Profissional Python !

MatLab

NumPy SciPy matplotlib

python™ IP[y]: IPython jupyter

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

18

## Python Open D. S. Stack

pandas
scikit learn
scikit-image
image processing in python
NumPy
SciPy
matplotlib
python
IP[y]: IPython
jupyter

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

19

## Python Open D. S. Stack

statsmodels
seaborn
pandas
scikit learn
scikit-image
image processing in python
NumPy
SciPy
matplotlib
python
IP[y]: IPython
jupyter

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

20

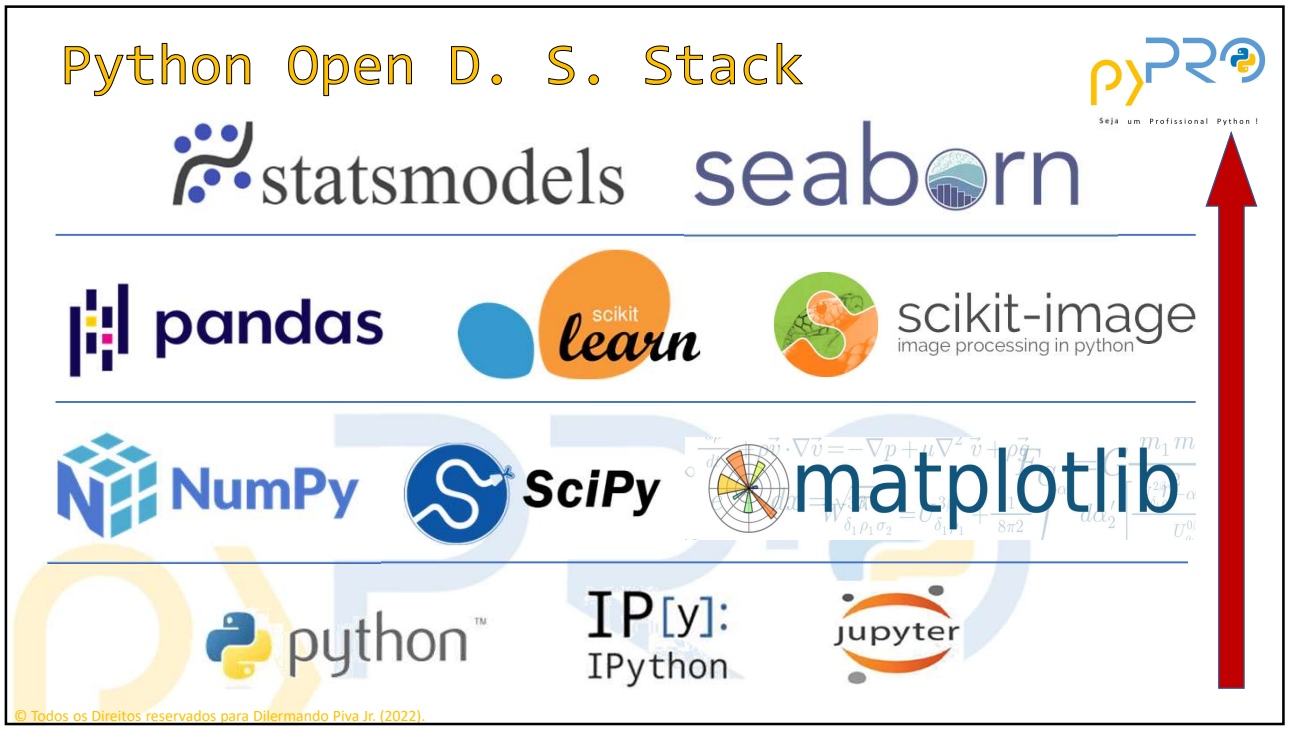
Python Open D. S. Stack
pyPRO
Seja um Profissional Python !
statsmodels
seaborn
pandas
scikit learn
scikit-image
image processing in python
NumPy
SciPy
matplotlib
python
IP[y]:
IPython
jupyter
© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

pyPRO
Seja um Profissional Python !

# Os Principais Pacotes

NumPy

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).



## NumPy – Numerical Python

- É um pacote fundamental para computação matemática em Python.
- Fornece suporte para arrays e matrizes, além de uma série de funções matemáticas para operações com esses objetos.
- O pacote NumPy nasceu de vários esforços para prover uma solução *open-source* ao Matlab.

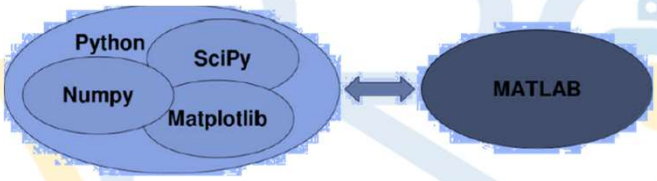


© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

# NumPy – Numerical Python

- Operações de álgebra linear
- Operações para manipulação de Arrays Multidimensionais
- Ferramentas de leitura de datasets baseados em arrays
- Série de ferramentas de análise de dados

NumPy é mais eficiente para armazenar e manipular dados numéricos do que qualquer estrutura built-in em Python

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).



# NumPy – Numerical Python

O que é um Array?

Conjunto de valores, todos do mesmo tipo, indexados por uma tupla de valores não-negativos

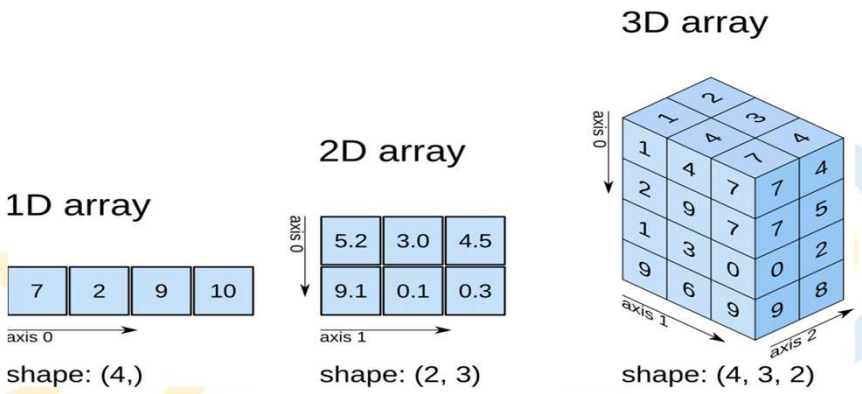


© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

# NumPy – Numerical Python

Seja um Profissional Python !

Install Documentation Learn Community About Us News Contribute

NumPy

The fundamental package for scientific computing with Python

LATEST RELEASE: NUMPY 1.24.2. VIEW ALL RELEASES.

**Meet the new NumPy docs team leads**

POWERFUL N-DIMENSIONAL ARRAYS

Fast and versatile, the NumPy vectorization, indexing, and broadcasting concepts are the de-facto standards of array computing today.

NUMERICAL COMPUTING TOOLS

NumPy offers comprehensive mathematical functions, random number generators, linear algebra routines, Fourier transforms, and more.

OPEN SOURCE

Distributed under a liberal BSD license, NumPy is developed and maintained publicly on GitHub by a vibrant, responsive, and diverse community.

INTEROPERABLE

PERFORMANT

EASY TO USE

**numpy.org**

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).



Seja um Profissional Python !

# Os Principais Pacotes

## Matplotlib

matplotlib

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

29

## Matplotlib

- É a biblioteca Python mais popular para visualização de dados e geração de gráficos
- Permite a criação de gráficos interativos quando utilizado dentro do Jupyter Notebook
- Permite a criação rápida e fácil de gráficos, histogramas e outras visualizações profissionais

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

30

# Matplotlib

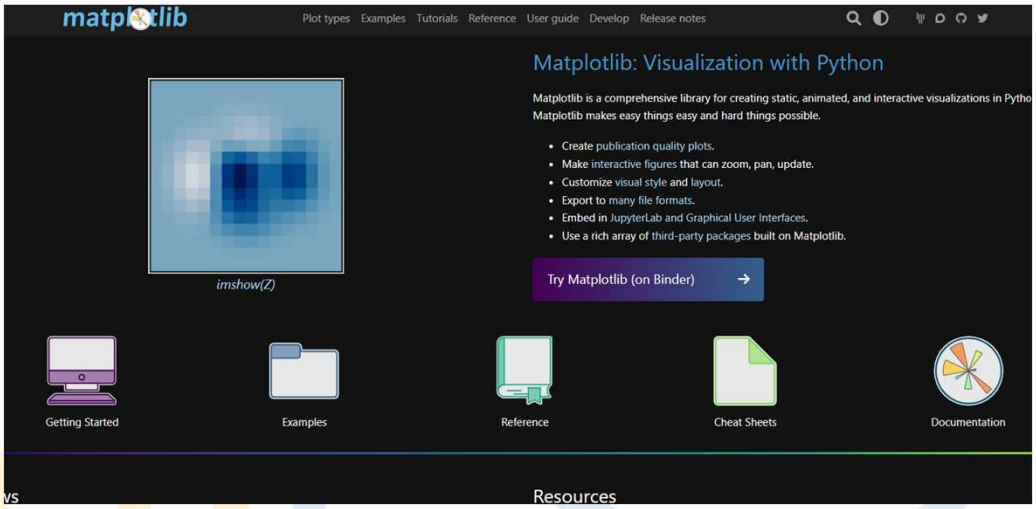


**matplotlib.org**

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).



Seja um Profissional Python !

# Os Principais Pacotes

SciPy

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).



## SciPy

- Coleção de pacotes que tratam funcionalidades específicas em computação científica
- SciPy possui um conjunto de algoritmos matemáticos e funções que permitem estender as funcionalidades do NumPy
- NumPy é um subconjunto do SciPy

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

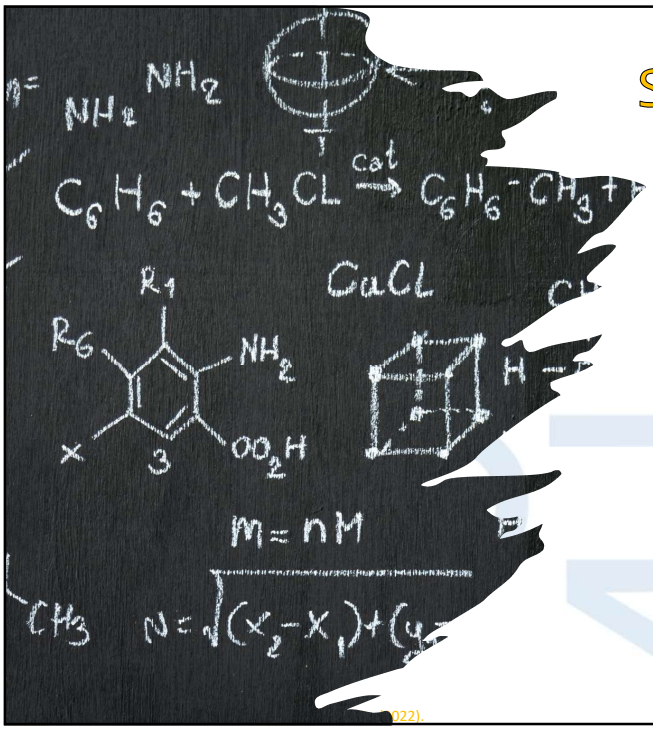

# SciPy

- Álgebra Linear
- Matrizes esparsas
- Números randômicos
- Transformações Fast Fourier
- Estimativa de Densidade
- Otimização
- Processamento de Sinais e Imagens

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).



# SciPy

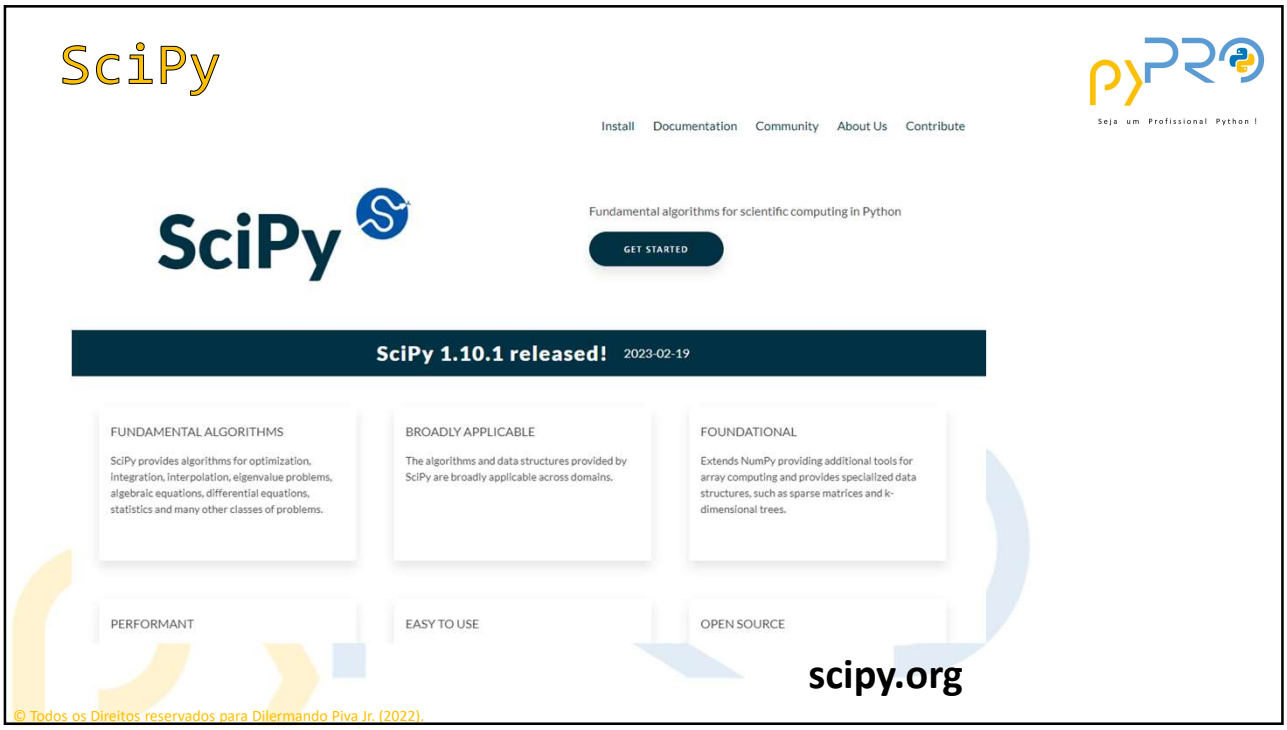


**scipy.org**

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

Seja um Profissional Python !

37

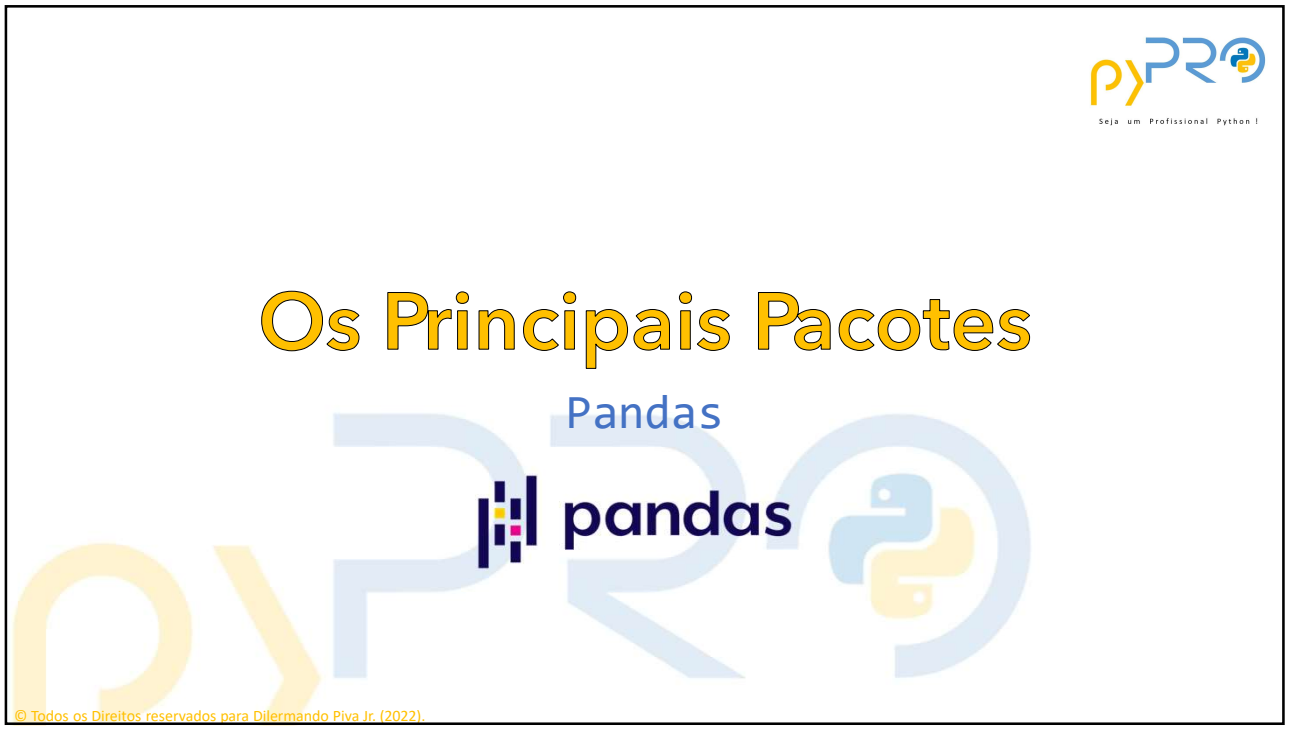
Seja um Profissional Python !
Os Principais Pacotes
Pandas
pandas
© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

38

# Pandas

É UMA BIBLIOTECA CRIADA PARA MANIPULAR DE FORMA RÁPIDA E EXPRESSIVA, DADOS ESTRUTURADOS

É UMA DAS PRINCIPAIS FERRAMENTAS PARA ANÁLISE DE DADOS

POSSUI UMA SOFISTICADA FUNCIONALIDADE DE INDEXAÇÃO O QUE TORNA FÁCIL O "*SLICE AND DICE*", AGREGAÇÕES E SELEÇÃO DE *SUBSETS* DE DADOS

É LARGAMENTE UTILIZADO PARA A PREPARAÇÃO DOS DADOS, UMA DAS FASES MAIS IMPORTANTES DO PROCESSO DE CIÊNCIA DE DADOS

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).



# Pandas

- Estruturas de Alto nível e ferramentas de manipulação para Análise de Dados...
- Pandas + NumPy propiciam:

ESTRUTURAS DE DADOS DE ALTO NÍVEL

FUNCIONALIDADE DE SÉRIES TEMPORAIS

UMA MESMA ESTRUTURA CONSEGUE TRATAR DADOS TEMPORAIS E NÃO-TEMPORAIS

TRATAMENTO FLEXÍVEL DE "DADOS FALTANTES"

MERGE E OUTRAS OPERAÇÕES RELACIONAIS COM SQL

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

# Pandas

- Principais Estruturas...

**Series** + **Series** = **DataFrame**

| | apples |
|---|---|
| 0 | 3 |
| 1 | 2 |
| 2 | 0 |
| 3 | 1 |

| | oranges |
|---|---|
| 0 | 0 |
| 1 | 3 |
| 2 | 7 |
| 3 | 2 |

| | apples | oranges |
|---|---|---|
| 0 | 3 | 0 |
| 1 | 2 | 3 |
| 2 | 0 | 7 |
| 3 | 1 | 2 |

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).



# Pandas

- SÉRIES
  - Séries é um array unidimensional que contém um array de dados e um array de labels, chamado índice

```
In [1]: from pandas import Series
        # Criando uma série e seus índices
        serie = Series([4, 5, -2, 1], index = ['x', 'y', 'z', 'r'])

In [2]: serie

Out[2]: x    4
        y    5
        z   -2
        r    1
        dtype: int64
```

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

# Pandas

- DATAFRAMES
  - Estrutura tabular contendo uma coleção de colunas e linhas

```
In [3]: dados = {'Cidade':['Itu', 'Sorocaba', 'Campinas', 'Votorantim', 'Salto'],
                 'Ano': [2018, 2019, 2020, 2021, 2022],
                 'População': [200, 700, 1300, 150, 130]}

In [4]: quadro = DataFrame(dados)

In [5]: quadro
```

Out[5]:

| | Cidade | Ano | População |
|---|---|---|---|
| 0 | Itu | 2018 | 200 |
| 1 | Sorocaba | 2019 | 700 |
| 2 | Campinas | 2020 | 1300 |
| 3 | Votorantim | 2021 | 150 |
| 4 | Salto | 2022 | 130 |

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).



# Pandas

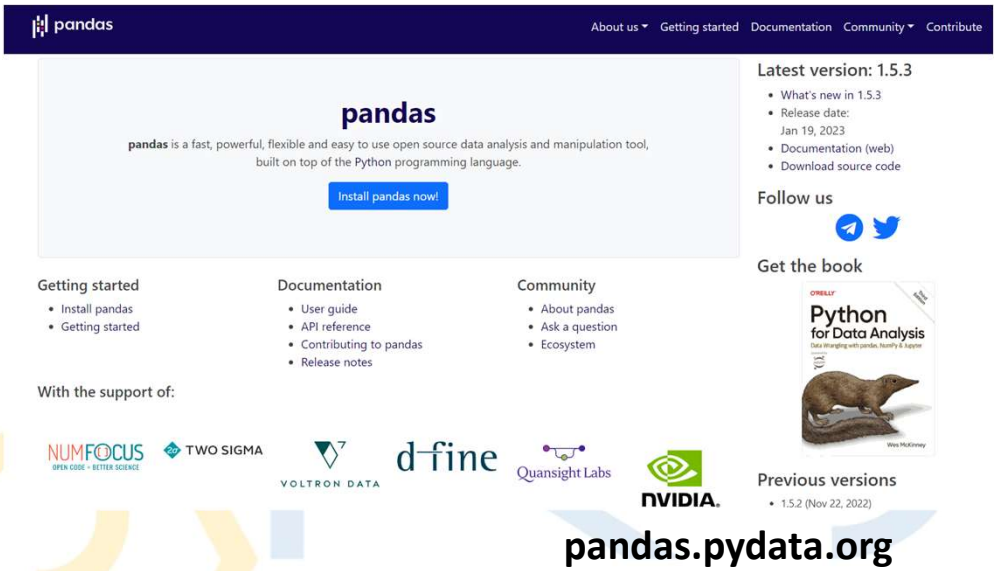


**pandas.pydata.org**

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

Seja um Profissional Python !

45

Seja um Profissional Python !

# Os Principais Pacotes

## Scikit-Learn

scikit learn

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

46

# Scikit-Learn

- É a biblioteca mais poderosa para Machine Learning (aprendizado de máquina) em Python
- Scikit-Learn + NumPy + SciPy + MatplotLib
  - Criação de ferramentas eficientes de Machine Learning e modelagem estatística como classificação, regressão, clusterização e redução de dimensionalidade.

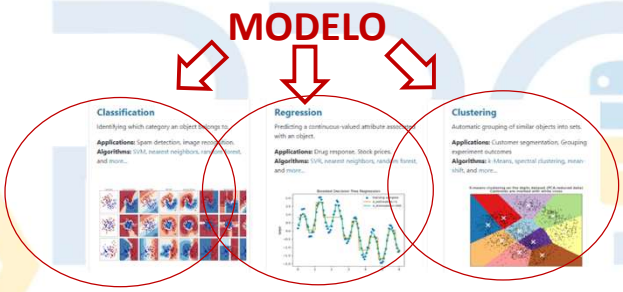


© Todos os Direitos reservados para Dilermando Piva Jr. (2022).



# Scikit-Learn

- Aprendizagem Supervisionada e Não-Supervisionada

Dados Rotulados

Dados Não-Rotulados

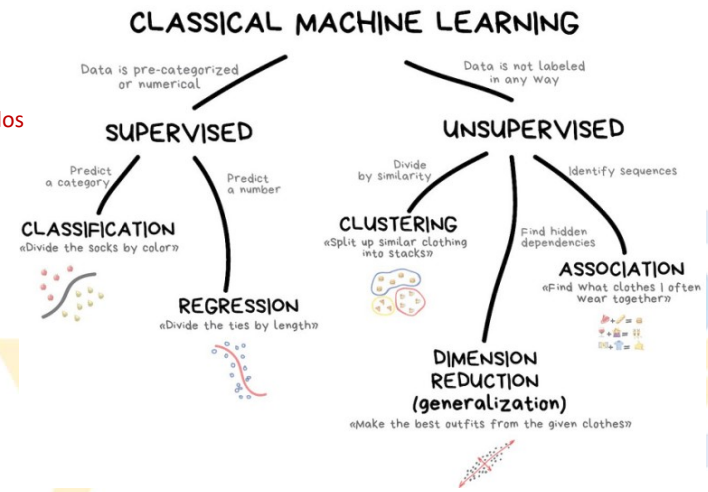


© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

# Scikit-Learn

- Aprendizagem de Máquina

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).



# Scikit-Learn

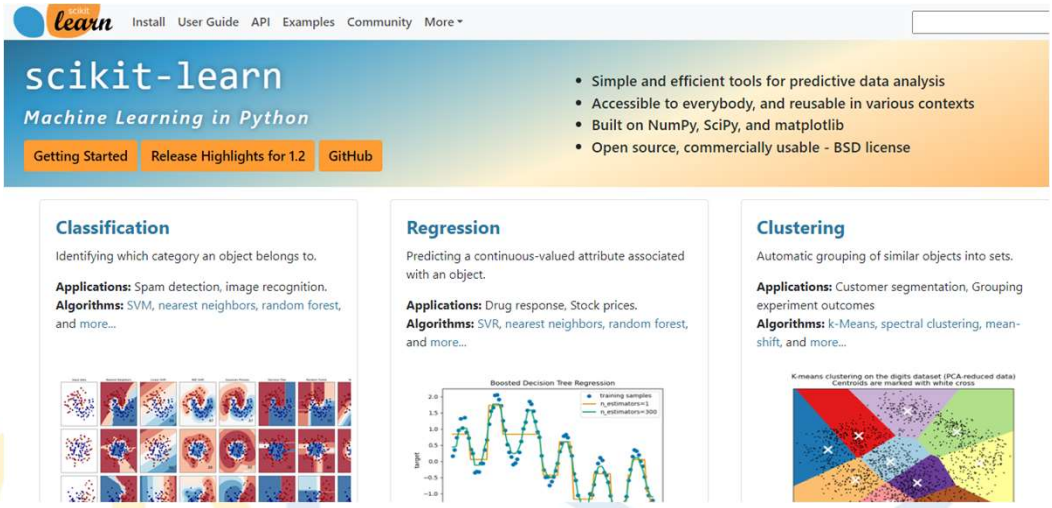


**scikit-learn.org**

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

pyPRO
Seja um Profissional Python !

51

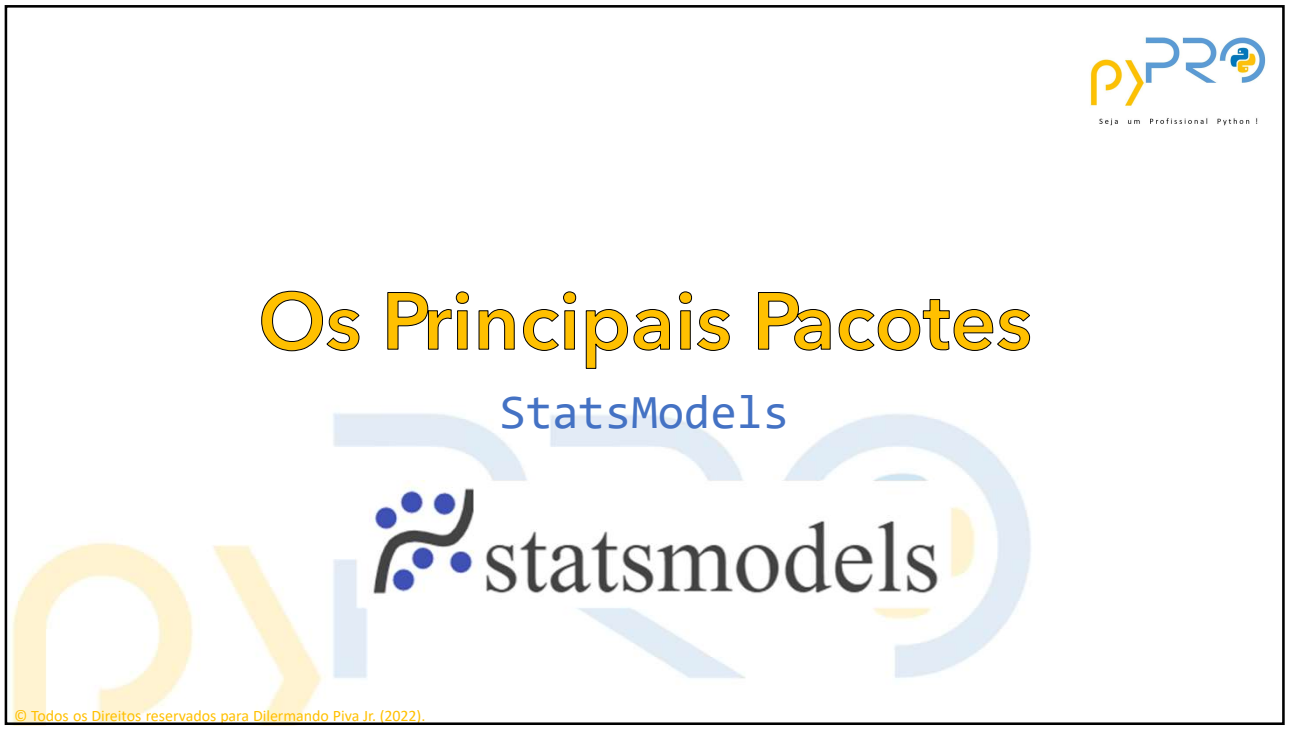
pyPRO
Seja um Profissional Python !
Os Principais Pacotes
StatsModels
statsmodels
© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

52

# StatsModels

- É uma das principais bibliotecas de Funções Estatísticas para Python

## Examples

This page provides a series of examples, tutorials and recipes to help you get started with `statsmodels`. Each of the examples shown here is made available as an IPython Notebook and as a plain python script on the statsmodels github repository.

We also encourage users to submit their own examples, tutorials or cool *statsmodels* trick to the Examples wiki page

### Linear Regression Models

Ordinary Least Squares | Generalized Least Squares | Quantile Regression

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).



# StatsModels

statsmodels 0.13.5 | Search | statsmodels 8.3k Stars · 2.7k Forks

statistical models, hypothesis tests, and data exploration

statsmodels 0.13.5
- Installing statsmodels
- Getting started
- User Guide
- Examples
- API Reference
- About statsmodels
- Developer Page
- Release Notes

## statsmodels

statsmodels is a Python module that provides classes and functions for the estimation of many different statistical models, as well as for conducting statistical tests, and statistical data exploration. An extensive list of result statistics are available for each estimator. The results are tested against existing statistical packages to ensure that they are correct. The package is released under the open source Modified BSD (3-clause) license. The online documentation is hosted at statsmodels.org.

Contents
- Introduction
- Citation
- Index
- Show Source

### Introduction

`statsmodels` supports specifying models using R-style formulas and `pandas` DataFrames. Here is a simple example using ordinary least squares:

```
In [1]: import numpy as np
```

**statsmodels.org**

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

pyPRO
Seja um Profissional Python !

55

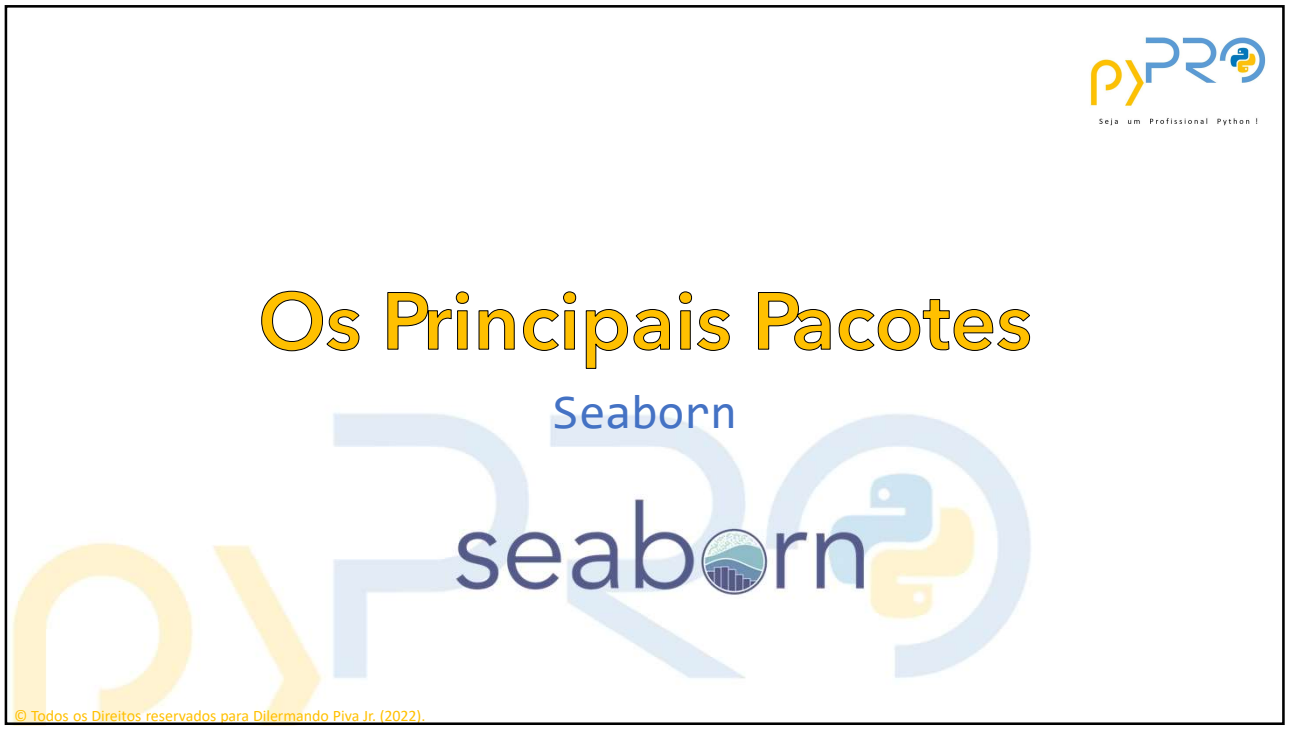
pyPRO
Seja um Profissional Python !
Os Principais Pacotes
Seaborn
seaborn
© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

56

# Seaborn

- Uma poderosa biblioteca utilizada para construir gráficos estatísticos atraentes e informativos em Python
- Foi construída sob a base da Matplotlib (estende suas funcionalidades)

Example gallery

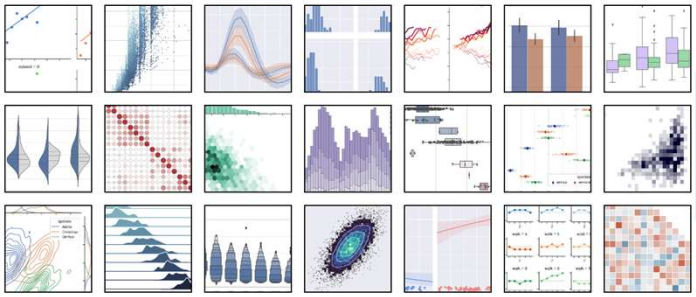

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).



# Seaborn

seaborn  Installing Gallery Tutorial API Releases Citing FAQ

seaborn: statistical data visualization

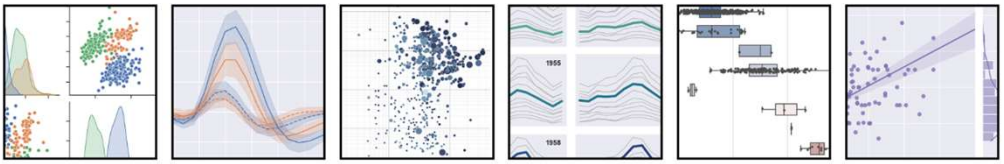

Seaborn is a Python data visualization library based on matplotlib. It provides a high-level interface for drawing attractive and informative statistical graphics.

For a brief introduction to the ideas behind the library, you can read the introductory notes or the paper. Visit the installation page to see how you can download the package and get started with it. You can browse the example gallery to see some of the things that you can do with seaborn, and then check out the tutorials or API reference to find out how.

To see the code or report a bug, please visit the GitHub repository. General support questions are most at home on stackoverflow, which has a dedicated channel for seaborn.

**Contents**

Installing
Gallery
Tutorial
API
Releases
Citing

**Features**

- New Objects: API | Tutorial
- Relational plots: API | Tutorial
- Distribution plots: API | Tutorial
- Categorical plots: API | Tutorial
- Regression plots: API | Tutorial
- Multi-plot grids: API | Tutorial
- Figure theming: API | Tutorial

**seaborn.pydata.org**

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).