pyPRO
Seja um Profissional Python !

1

pyPRO
Seja um Profissional Python !
Limpeza dos Dados
Estratégias de Limpeza dos Dados e Tratamento de Valores ausentes
© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

2

O que é limpeza de dados?

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

3

O que é limpeza de dados?

É o processo de corrigir, padronizar ou remover dados incorretos, corrompidos, formatados incorretamente, duplicados ou incompletos em um conjunto de dados.

DATACLEAN

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

4

O que é limpeza de dados?

Seja um Profissional Python !

Ao manusear os dados, principalmente quando envolvem várias fontes de dados, podem ocorrer duplicação ou rotulagem incorreta dos dados.

Entrada incorreta → Saída incorreta

DATACLEAN

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

5

O que é limpeza de dados?

Seja um Profissional Python !

Ao manusear os dados, principalmente quando envolvem várias fontes de dados, podem ocorrer duplicação ou rotulagem incorreta dos dados.

Entrada incorreta → Saída incorreta

MESMO PARECENDO CORRETOS!!

DATACLEAN

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

6

O que é limpeza de dados?

Ao manusear os dados, principalmente quando envolvem várias fontes de dados, podem ocorrer duplicação ou rotulagem incorreta dos dados.

Entrada incorreta → Saída incorreta

MESMO PARECENDO CORRETOS!!

Exemplo: Valores Outlier
Valores que se distanciam muito dos demais dados que compõem uma amostra (valores atípicos)

Se não forem removidos, vão causar um impacto na média dos dados e nas demais conclusões que fizermos sobre aqueles dados

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

O que é limpeza de dados?

Não há uma forma absoluta de prescrever as etapas exatas no processo de limpeza de dados, pois para cada problema de negócio, para cada conjunto de dados, haverá uma conformação específica dos dados.

Não existe um script fechado!

EXISTE SIM ESTRATÉGIAS (PARA CADA SITUAÇÃO).

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

O que é limpeza de dados?

Principais estratégias/técnicas de limpeza de dados !!!

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

Processo de Análise dos Dados

Problema de Negócio

Coleta dos Dados → Entendimento e Limpeza dos Dados → Análise Exploratória

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

Processo de Análise dos Dados

Problema de Negócio

Coleta dos Dados → Entendimento e Limpeza dos Dados → Análise Exploratória

80% do Trabalho de um Cientista / Analista de Dados

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

Processo de Análise dos Dados

Problema de Negócio

Coleta dos Dados e Inspeção → Entendimento e Limpeza dos Dados → Análise Exploratória

- Identificação e Deleção de Dados Duplicados
- Correção de dados Incompletos ou Irrelevantes
- Tratamento de Dados (detalhes) Ausentes
- Tratamento de valores outliers (valores extremos)
- Padronizar e Normalizar os Dados
- Identificação de variáveis chaves
- Sugestão de novas variáveis
- Correção erros de digitação/formato
- Conversão dos tipos de dados
- Remover espaços ou zeros desnecessários (ex. 000726 p/ 726)

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

Processo de Análise dos Dados

Problema de Negócio

Coleta dos Dados e Inspeção → Entendimento e Limpeza dos Dados → Análise Exploratória

- Identificação e Deleção de Dados Duplicados
- Correção de dados Incompletos ou Irrelevantes
- Tratamento de Dados (detalhes) Ausentes
- Tratamento de valores outliers (valores extremos)
- Padronizar e Normalizar os Dados
- Identificação de variáveis chaves
- Sugestão de novas variáveis
- Correção erros de digitação/formato
- Conversão dos tipos de dados
- Remover espaços ou zeros desnecessários (ex. 000726 p/ 726)

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

Processo de Análise dos Dados

ATENÇÃO!!!

TODA E QUALQUER TÉCNICA DE LIMPEZA DE DADOS CAUSA IMPACTO NA ANÁLISE DE DADOS E TODAS AS ESCOLHAS DEVEM SER JUSTIFIDADAS.

Problema de Negócio

- ~~Identificação e Deleção de Dados Duplicados~~
- Correção de dados Incompletos ou Irrelevantes
- Tratamento de Dados (detalhes) Ausentes
- Tratamento de valores outliers (valores extremos)
- Padronizar e Normalizar os Dados
- Identificação de variáveis chaves
- Sugestão de novas variáveis
- Correção erros de digitação/formato
- Conversão dos tipos de dados
- Remover espaços ou zeros desnecessários (ex. 000726 p/ 726)

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

Processo de Análise dos Dados

pode ser necessário refazer o processo de limpeza (várias e várias vezes)

Problema de Negócio

- Identificação e Deleção de Dados Duplicados
- Correção de dados Incompletos ou Irrelevantes
- Tratamento de Dados (detalhes) Ausentes
- Tratamento de valores outliers (valores extremos)
- Padronizar e Normalizar os Dados
- Identificação de variáveis chaves
- Sugestão de novas variáveis
- Correção erros de digitação/formato
- Conversão dos tipos de dados
- Remover espaços ou zeros desnecessários (ex. 000726 p/ 726)

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

15

Processo de Análise dos Dados

A estratégia / técnica ideal de limpeza é aquela que transforma os dados em um formato ideal para análise

Problema de Negócio

- Correção de dados Incompletos ou Irrelevantes
- Tratamento de Dados (detalhes) Ausentes
- Tratamento de valores outliers (valores extremos)
- Padronizar e Normalizar os Dados
- Identificação de variáveis chaves
- Sugestão de novas variáveis
- Correção erros de digitação/formato
- Conversão dos tipos de dados
- Remover espaços ou zeros desnecessários (ex. 000726 p/ 726)

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

16

Como avaliar o antes e o depois da Limpeza de Dados?

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

17

Estratégias...

- Evite aplicar muitas técnicas de limpeza ao mesmo tempo.
  1. Avalie os dados antes de aplicar uma técnica (com base no problema / nas perguntas de negócio)
  2. APLIQUE A TÉCNICA (1 técnica apenas)
  3. Avalie os dados após a aplicação dessa técnica (e veja se ela ofereceu algum ganho / qualidade nos dados).

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

18

Estratégias...

- Evite aplicar muitas técnicas de limpeza ao mesmo tempo.
  1. Avalie os dados antes de aplicar uma técnica (com base no problema / nas perguntas de negócio) ➔ CRIE UMA CÓPIA
  2. APLIQUE A TÉCNICA (1 técnica apenas)
  3. Avalie os dados após a aplicação dessa técnica (e veja se ela ofereceu algum ganho / qualidade nos dados).

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

Estratégias...

- Evite aplicar muitas técnicas de limpeza ao mesmo tempo.
  1. Avalie os dados antes de aplicar uma técnica (com base no problema / nas perguntas de negócio)
  2. APLIQUE A TÉCNICA (1 técnica apenas)
  3. Avalie os dados após a aplicação dessa técnica (e veja se ela ofereceu algum ganho / qualidade nos dados).

Faça isso quantas vezes for necessário!

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

Estratégias...

- Evite aplicar muitas técnicas de limpeza ao mesmo tempo.
  1. Avalie os dados antes de aplicar uma técnica (com base no problema / nas perguntas de negócio)
  2. APLIQUE A TÉCNICA (1 técnica apenas)
  3. Avalie os dados após a aplicação dessa técnica (e veja se ela ofereceu algum ganho / qualidade nos dados).

Faça isso quantas vezes for necessário!

Justifique, em um relatório, o porquê da transformação. Para cada técnica utilizada.
➔ LGPD

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

Estratégias...

- Evite aplicar muitas técnicas de limpeza ao mesmo tempo.
  1. Avalie os dados antes de aplicar uma técnica (com base no problema / nas perguntas de negócio)
  2. APLIQUE A TÉCNICA (1 técnica apenas)
  3. Avalie os dados após a aplicação dessa técnica (e veja se ela ofereceu algum ganho / qualidade nos dados).

Faça isso quantas vezes for necessário!

- Salve Resultados Intermediários para evitar Reprocessamento

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

Principais estratégias de limpeza

Problema de Negócio

Coleta dos Dados e Inspeção → Entendimento e Limpeza dos Dados → Análise Exploratória

- Identificação e Deleção de Dados Duplicados
- Correção de dados Incompletos ou Irrelevantes
- **Tratamento de Dados (detalhes) Ausentes**
- **Tratamento de valores outliers (valores extremos)**
- Padronizar e Normalizar os Dados
- Identificação de variáveis chaves
- Sugestão de novas variáveis
- Correção erros de digitação/formato
- **Conversão dos tipos de dados**
- Remover espaços ou zeros desnecessários (ex. 000726 p/ 726)

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

Principais estratégias de limpeza

- **Conversão de Tipos de Dados**
  - Os tipos de dados estão corretos e adequados para realizar a análise dos dados (conforme o problema?)
  - A conversão pode causar perda de dados (ex: float → int)
  - Tipo de dados Data e Hora (datetime) são os mais trabalhosos e delicados para conversão
  - A conversão tem que ser feita baseada na informação que precisamos extrair daquele campo em específico (problema...)

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

Principais estratégias de limpeza

- **Tratamento de Valores Ausentes**
  - Valores ausentes representam um problema e deve ser tratado!!
  - Valor ausente → Falta de Informação (e não dados). Por exemplo: idade deve conter um valor... Entretanto, se existir um 0 ou ? Isso pode significar valor ausente (todavia o dado está lá).

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

Principais estratégias de limpeza

- **Tratamento de Valores Ausentes**
  - Valores ausentes representam um problema e deve ser tratado!!
  - Valor ausente → Falta de Informação (e não dados). Por exemplo: idade deve conter um valor... Entretanto, se existir um 0 ou ? Isso pode significar valor ausente (todavia o dado está lá).

Id (CPF)	Idade	Estado Civil
111.259.999-45	45	Casado
125.259.439-85		Solteiro

Id (CPF)	Idade	Estado Civil
111.259.999-45	45	Casado
125.259.439-85	?	Solteiro

Id (CPF)	Idade	Estado Civil
111.259.999-45	45	Casado
125.259.439-85	-1	Solteiro

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

Principais estratégias de limpeza

- **Tratamento de Valores Ausentes**
  - Valores ausentes representam um problema e deve ser tratado!!
  - Valor ausente → Falta de Informação (e não dados). Por exemplo: idade deve conter um valor... Entretanto, se existir um 0 ou ? Isso pode significar valor ausente (todavia o dado está lá).

Id (CPF)	Idade	Estado Civil
111.259.999-45	45	Casado
125.259.439-85		Solteiro

Id (CPF)	Idade	Estado Civil
111.259.999-45	45	Casado
125.259.439-85	?	Solteiro

Id (CPF)	Idade	Estado Civil
111.259.999-45	45	Casado
125.259.439-85	-1	Solteiro

Sempre vá a fonte para verificar o Porquê desses valores ausentes!!!

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

Principais estratégias de limpeza

- **Tratamento de Valores Ausentes**
  - Valores ausentes representam um problema e deve ser tratado!!
  - Valor ausente → Falta de Informação (e não dados). Por exemplo: idade deve conter um valor... Entretanto, se existir um 0 ou ? Isso pode significar valor ausente (todavia o dado está lá).
  - Remoção ou Imputação de Dados?
    - Remoção → >= 30% de valores ausentes
    - Imputação → < 30 % - Qtd (média/mediana)
      - Qlt (analisar e decidir)

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

Principais estratégias de limpeza

- **Tratamento de Valores Ausentes**
  - O que não se deve fazer?
    - Não preencha valores ausentes com valores aleatórios ou sem critério
    - Não use a média para preencher valores ausentes em variável quantitativa se esta não apresentar uma distribuição normal (moda e mediana seriam melhores opções)
    - Não invente categorias p/ tratar variáveis qualitativas (use termos como "outros" ou "não definido")
    - Não faça suposições. TENHA CERTEZA SEMPRE!!

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

Principais estratégias de limpeza

- **Tratamento de Valores Ausentes**
  - Principais técnicas para tratamento de valores ausentes
    - Deleção dos registros (casos)
    - Imputação de Dados
      - Imputação Múltipla
      - Imputação por Regressão
      - Imputação por observação do anterior ou do próximo registro
    - Técnicas com *Machine Learning*
      - Análise sensitiva
      - Maximização da expectativa
      - Knn
      - Semelhança máxima

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

Principais estratégias de limpeza

- **Tratamento de Valores Ausentes**
  - Remoção ou Imputação de Dados?
    - Remoção → coluna >= 30% de valores ausentes
      linha → que não esteja 100% preenchida
    - Imputação → coluna < 30 %
      - Qtd (média/mediana/moda)
      - Qlt (analisar e decidir
        → Nova categoria)

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

Principais estratégias de limpeza

- **Tratamento de Valores Outliers (valores extremos)**
  - Valores extremos podem ou não representar um problema.
  - Valores quantitativos que possuem outliers, impactam no cálculo da média
  - Dependendo do projeto, os valores extremos são exatamente o que queremos analisar (Ex: fraudes)
  - Devemos remover valores extremos de forma balanceada abaixo de Q1 e acima de Q3 (na mesma proporção)

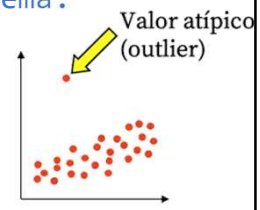

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

Principais estratégias de limpeza

Problema de Negócio

Coleta dos Dados e Inspeção → Entendimento e Limpeza dos Dados → Análise Exploratória

- Identificação e Deleção de Dados Duplicados
- Correção de dados Incompletos ou Irrelevantes
- **Tratamento de Dados (detalhes) Ausentes**
- **Tratamento de valores outliers (valores extremos)**
- Padronizar e Normalizar os Dados
- Identificação de variáveis chaves
- Sugestão de novas variáveis
- Correção erros de digitação/formato
- **Conversão dos tipos de dados**
- Remover espaços ou zeros desnecessários (ex. 000726 p/ 726)

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).