1

# Transformação e Codificação de Variáveis

Estratégias de manipulação e transformação dos tipos de dados das variáveis

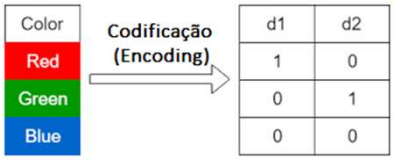


© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

2

# O que é Transformação de uma variável?

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

3

# O que é transformar uma variável?

É o processo ou ação de modificar o valor ou o tipo de uma variável ... Aplicar alterações ou manipulações em uma variável existente a fim de extrair informações úteis, ajustar a escala de dados, criar novas variáveis derivadas ou preparar os dados para análises mais avançadas.

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

4

# O que é transformar uma variável?

Seja um Profissional Python !

Em um conjunto de dados...

STRING

| Experiência Profissional |
|---|
| 6 |
| 2 |
| 16 |

Está correta essa categorização ?

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

5

# O que é transformar uma variável?

Seja um Profissional Python !

Em um conjunto de dados...

STRING

| Experiência Profissional |
|---|
| 6 |
| 2 |
| 16 |

Está correta essa categorização ?

Resposta: DEPENDE !!!

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

6

# O que é transformar uma variável?

Em um conjunto de dados...

STRING

| Experiência Profissional |
|---|
| 6 |
| 2 |
| 16 |

Para que você vai utilizar essa variável

?

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).



# O que é transformar uma variável?

Em um conjunto de dados...

STRING

| Experiência Profissional |
|---|
| 6 |
| 2 |
| 16 |

Transformar

NUMÉRICO

| Experiência Profissional |
|---|
| 6 |
| 2 |
| 16 |

Vamos usá-la para calcular a média ou qualquer outro cálculo matemático...

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

# O que é transformar uma variável?

Seja um Profissional Python !

## Em um conjunto de dados...

STRING

| Experiência Profissional |
|---|
| 6 |
| 2 |
| 16 |

Transformar

NUMÉRICO

| Experiência Profissional |
|---|
| 6 |
| 2 |
| 16 |

Vamos usá-la para gerar gráficos por categoria...

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).



# O que é transformar uma variável?

Seja um Profissional Python !

## Em um conjunto de dados...

STRING

| Experiência Profissional |
|---|
| 6 |
| 2 |
| 16 |

Transformar

NUMÉRICO

| Experiência Profissional |
|---|
| 6 |
| 2 |
| 16 |

Transformar

CATEGORIA (FAIXA DE EXPERIÊNCIA)

| Experiência Profissional |
|---|
| 5 a 10 anos |
| 1 a 5 anos |
| 11 a 20 anos |

Vamos usá-la para gerar gráficos por categoria...

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

# O que é transformar uma variável?

Seja um Profissional Python !

## Mais um exemplo...

STRING

| Porte da Empresa |
|---|
| Pequena |
| Média |
| Grande |

Tenho que aplicar algum tipo de transformação nessa variável?

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).



# O que é transformar uma variável?

Seja um Profissional Python !

## Mais um exemplo...

STRING

| Porte da Empresa |
|---|
| Pequena |
| Média |
| Grande |

Vou utilizar essa variável como entrada para um modelo de Machine Learning....

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

# O que é transformar uma variável?

Seja um Profissional Python !

Mais um exemplo...

STRING

| Porte da Empresa |
|---|
| Pequena |
| Média |
| Grande |

Transformar

NUMÉRICO

| Porte da Empresa |
|---|
| 1 |
| 2 |
| 3 |

Vou utilizar essa variável como entrada para um modelo de Machine Learning....

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).



# O que é transformar uma variável?

Seja um Profissional Python !

Assim....

Transformar uma variável significa convertê-la para um formato apropriado para o objetivo da análise daquele projeto em específico!!!

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

# O que é Codificação (Encoding)?

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

15

# O que é codificação de variável?

É o processo ou ação de converter variáveis categóricas (ou qualitativas) em uma forma numérica que possa ser facilmente processada por algoritmos de aprendizado de máquina ou outros modelos estatísticos.

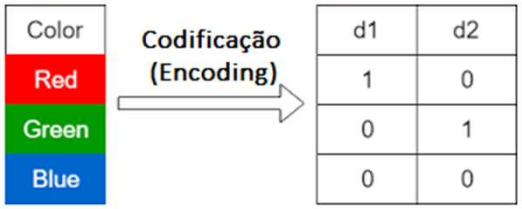


© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

16

## O que é codificação de variável?

Existem várias técnicas de codificação...as mais conhecidas são: Encoding Ordinal, One-Hot Encoding, Binary Encoding, Label Encoding e Count/Frequency Encoding.

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

17

## O que é codificação de variável?

Existem várias técnicas de codificação...as mais conhecidas são: Encoding Ordinal, One-Hot Encoding, Binary Encoding, Label Encoding e Count/Frequency Encoding.

**Nesse método, as categorias são atribuídas a números inteiros em uma ordem específica. Isso é adequado quando existe uma relação de ordem natural entre as categorias. Por exemplo, para a variável "tamanho" com as categorias "pequeno", "médio" e "grande", pode-se atribuir os valores 1, 2 e 3, respectivamente.**

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

18

## O que é codificação de variável?

Existem várias técnicas de codificação...as mais conhecidas são: Encoding Ordinal, One-Hot Encoding, Binary Encoding, Label Encoding e Count/Frequency Encoding.

**Nesse método, as categorias são atribuídas a números inteiros em uma ordem específica. Isso é adequado quando existe uma relação de ordem natural entre as categorias. Por exemplo, para a variável "tamanho" com as categorias "pequeno", "médio" e "grande", pode-se atribuir os valores 1, 2 e 3, respectivamente.**

**USO: Quando existe um número baixo de categorias**

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

19

## O que é codificação de variável?

Existem várias técnicas de codificação...as mais conhecidas são: Encoding Ordinal, One-Hot Encoding, Binary Encoding, Label Encoding e Count/Frequency Encoding.

**Nesse método, cada categoria é convertida em uma nova variável binária (0 ou 1). Para uma variável com N categorias distintas, são criadas N-1 novas variáveis binárias. Cada variável binária representa a presença ou ausência de uma determinada categoria. Esse método evita a imposição de uma ordem entre as categorias e é amplamente utilizado em problemas de aprendizado de máquina.**

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

20

# O que é codificação de variável?

Existem várias técnicas de codificação...as mais conhecidas são: Encoding Ordinal, One-Hot Encoding, Binary Encoding, Label Encoding e Count/Frequency Encoding.

**Nesse método, cada categoria é convertida em uma nova variável binária (0 ou 1). Para uma variável com N categorias distintas, são criadas N-1 novas variáveis binárias. Cada variável binária representa a presença ou ausência de uma determinada categoria. Esse método evita a imposição de uma ordem entre as categorias e é amplamente utilizado em problemas de aprendizado de máquina.**

Também conhecida como variável DUMMY

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).



# O que é codificação de variável?

Existem vá...as mais conhe One-Hot Encoding, ing e Count/Freq

| Resultado Exame | Resultado Positivo | Resultado Negativo | Resultado não-conclusivo |
|---|---|---|---|
| Positivo | 1 | 0 | 0 |
| Negativo | 0 | 1 | 0 |
| Não-Conclusivo | 0 | 0 | 1 |

**Nesse método, cada categoria é convertida em uma nova variável binária (0 ou 1). Para uma variável com N categorias distintas, são criadas N-1 novas variáveis binárias. Cada variável binária representa a presença ou ausência de uma determinada categoria. Esse método evita a imposição de uma ordem entre as categorias e é amplamente utilizado em problemas de aprendizado de máquina.**

Também conhecida como variável DUMMY

**USO: Quando precisamos estabelecer uma relação binária entre as categorias**

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

# O que é codificação de variável?

Existem vá ...as
mais conhe One-Hot
Encoding, ing e
Count/Freq

| Resultado Exame | Resultado Positivo | Resultado Negativo | Resultado não-conclusivo |
|---|---|---|---|
| Positivo | 1 | 0 | 0 |
| Negativo | 0 | 1 | 0 |
| Não-Conclusivo | 0 | 0 | 1 |

**Nesse método, cada categoria é convertida em uma nova variável binária (0 ou 1). Para uma variável com N categorias distintas, são criadas N-1 novas variáveis binárias. Cada variável binária representa a presença ou ausência de uma determinada categoria. Esse método evita a imposição de uma ordem entre as categorias e é amplamente utilizado em problemas de aprendizado de máquina.**

Também conhecida como variável DUMMY

**Limitação: número elevado de categorias**
**→ maldição da alta dimensionalidade**

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).



# O que é codificação de variável?

**MALDIÇÃO DA ALTA DIMENSIONALIDADE:**

1) **Espaço de Recursos Esparsos**: Com um grande número de dimensões, o espaço de recursos se torna extremamente disperso (valores mais distantes). Dificulta a identificação de padrões significativos nos dados.

2) **Superestimação de Correlações**: Com um grande número de variáveis, é mais provável que algumas delas apresentem correlações aparentes, mesmo que sejam apenas espúrias. Isso pode levar a conclusões enganosas ao analisar os dados, já que nem todas as correlações são verdadeiras ou úteis.

3) **Overfitting**: Modelos de aprendizado de máquina podem se tornar excessivamente complexos e sensíveis ao ruído nos dados quando confrontados com alta dimensionalidade. Isso pode levar ao overfitting, onde o modelo se ajusta muito bem aos dados de treinamento, mas falha em generalizar para novos dados.

4) **Dificuldade de Visualização**: Com mais dimensões, torna-se mais desafiador visualizar os dados.

5) **Requer Mais Dados para Manter a Precisão**: Com mais dimensões, é necessário um volume muito maior de dados para manter a mesma precisão estatística.

...as
One-Hot
ing e

va
rias
a
ma
de
em

Também conhecida como variável DUMMY

**→ maldição da alta dimensionalidade**

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

# O que é codificação de variável?

Existem várias técnicas de codificação...as mais conhecidas são: Encoding Ordinal, One-Hot Encoding, Binary Encoding, Label Encoding e Count/Frequency Encoding.

**Nesse método, as categorias são convertidas em sequências binárias únicas. Cada categoria é mapeada para uma sequência de bits, e cada bit representa a presença ou ausência de um determinado valor. Isso é útil quando há muitas categorias únicas e o one-hot encoding resultaria em uma quantidade excessiva de novas variáveis.**

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).



# O que é codificação de variável?

Existem várias técnicas de c
mais conhecidas são: Encodi
Encoding, Binary Encoding, L
Count/Frequency Encoding.

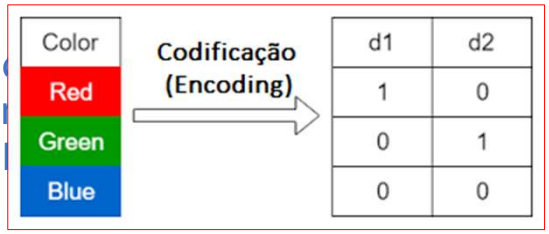


**Nesse método, as categorias são convertidas em sequências binárias únicas. Cada categoria é mapeada para uma sequência de bits, e cada bit representa a presença ou ausência de um determinado valor. Isso é útil quando há muitas categorias únicas e o one-hot encoding resultaria em uma quantidade excessiva de novas variáveis.**

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

# O que é codificação de variável?

Existem várias técnicas de codificação...as mais conhecidas são: Encoding Ordinal, One-Hot Encoding, Binary Encoding, Label Encoding e Count/Frequency Encoding.

**Nesse método, cada categoria é atribuída a um número inteiro único. Cada categoria recebe um valor numérico sequencial começando de 0. Esse método é adequado para variáveis categóricas ordinais ou quando a ordem das categorias não é importante.**

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

27

# O que é codificação de variável?

Existem várias técnicas de codificação...as mais conhecidas são: Encoding Ordinal, One-Hot Encoding, Binary Encoding, Label Encoding e Count/Frequency Encoding.

**Nesse método, cada categoria é atribuída a um número inteiro único. Cada categoria recebe um valor numérico sequencial começando de 0. Esse método é adequado para variáveis categóricas ordinais ou quando a ordem das categorias não é importante.**

**Essa técnica é utilizada, quando possuímos um número baixo de categorias (10 a 20)**

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

28

## O que é codificação de variável?

Existem várias técnicas de codificação...as mais conhecidas são: Encoding Ordinal, One-Hot Encoding, Binary Encoding, Label Encoding e Count/Frequency Encoding.

**Nesse método, cada categoria é atribuída a um número inteiro único. Cada categoria recebe um valor numérico sequencial começando de 0. Esse método é adequado para variáveis categóricas ordinais ou quando a ordem das categorias não é importante.**

**Limitação: não é adequado para modelos lineares como Regressão Logística.**

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).



## O que é codificação de variável?

Existem várias técnicas de codificação...as mais conhecidas são: Encoding Ordinal, One-Hot Encoding, Binary Encoding, Label Encoding e Count/Frequency Encoding.

**Nesse método, cada categoria é atribuída a um número inteiro único. Cada categoria recebe um valor numérico sequencial começando de 0. Esse método é adequado para variáveis categóricas ordinais ou quando a ordem das categorias não é importante.**

**Ex: maça – 0; banana – 1 e laranja – 2. Laranja é superior a maça?**

**Limitação: não é adequado para modelos lineares como Regressão Logística.**

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

## O que é codificação de variável?

Existem várias técnicas de codificação...as mais conhecidas são: Encoding Ordinal, One-Hot Encoding, Binary Encoding, Label Encoding e Count/Frequency Encoding.

**Nesse método, cada categoria é substituída por sua contagem ou frequência com que aparece no dataset. Por exemplo: se temos uma variável cor do automóvel... A cor verde aparece 34 vezes, a cor azul, 45 e a cor prata, 21. Esses números corresponderão a nova codificação dessa variável (CONTAGEM)**

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

31

## O que é codificação de variável?

Existem várias técnicas de codificação...as mais conhecidas são: Encoding Ordinal, One-Hot Encoding, Binary Encoding, Label Encoding e Count/Frequency Encoding.

**Nesse método, cada categoria é substituída por sua contagem ou frequência com que aparece no dataset. Por exemplo: se temos uma variável cor do automóvel... A cor verde aparece 34 vezes, a cor azul, 45 e a cor prata, 21. Por frequência teríamos: 0.34, 0.45 e 0.21, respectivamente.**

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

32

# O que é codificação de variável?

Existem várias técnicas de codificação...as mais conhecidas são: Encoding Ordinal, One-Hot Encoding, Binary Encoding, Label Encoding e Count/Frequency Encoding.

**Nesse método, cada categoria é substituída por sua contagem ou frequência com que aparece no dataset. Por exemplo: se temos uma variável cor do automóvel... A cor verde aparece 34 vezes, a cor azul, 45 e a cor prata, 21. Por frequência teríamos: 0.34, 0.45 e 0.21, respectivamente.**

**Essa técnica é utilizada, quando possuímos um número elevado de categorias**

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

33

# O que é codificação de variável?

Existem várias técnicas de codificação...as mais conhecidas são: Encoding Ordinal, One-Hot Encoding, Binary Encoding, Label Encoding e Count/Frequency Encoding.

**Nesse método, cada categoria é substituída por sua contagem ou frequência com que aparece no dataset. Por exemplo: se temos uma variável cor do automóvel... A cor verde aparece 34 vezes, a cor azul, 45 e a cor prata, 21. Por frequência teríamos: 0.34, 0.45 e 0.21, respectivamente.**

**LIMITAÇÃO: quando duas categorias tiverem a mesma frequência.**

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

34

# O que é codificação de variável?

Seja um Profissional Python !

Vamos imaginar a seguinte variável em seu dataset...

STRING

| Gênero |
|---|
| Masculino |
| Feminino |
| Outros |

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

35

# O que é codificação de variável?

Seja um Profissional Python !

Vamos imaginar a seguinte variável em seu dataset...

STRING

| Gênero |
|---|
| Masculino |
| Feminino |
| Outros |

ENCODING

NUMÉRICO

| Gênero (CODIFICADO) |
|---|
| 0 |
| 1 |
| 2 |

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

36

# O que é codificação de variável?

Seja um Profissional Python !

Vamos imaginar a seguinte variável em seu dataset...

STRING

| Gênero |
|---|
| Masculino |
| Feminino |
| Outros |

ENCODING

NUMÉRICO

| Gênero (CODIFICADO) |
|---|
| 0 |
| 1 |
| 2 |

**ATENÇÃO!!!**

**NO PROCESSO DE ENCODING, NÃO PODE OCORRER PERDA DE INFORMAÇÃO !!**

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).



# O que é codificação de variável?

Seja um Profissional Python !

Posso criar minha própria regra de Encoding?

STRING

| Gênero |
|---|
| Masculino |
| Feminino |
| Outros |

ENCODING

NUMÉRICO

| Gênero (CODIFICADO) |
|---|
| |
| |
| |

**SIM, CLARO!!**

**PRINCIPALMENTE SE VOCÊ CONHECE BEM O NEGÓCIO.**

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

# O que é codificação de variável?

Seja um Profissional Python !

## EVITE REALIZAR MUITAS TRANSFORMAÇÕES?

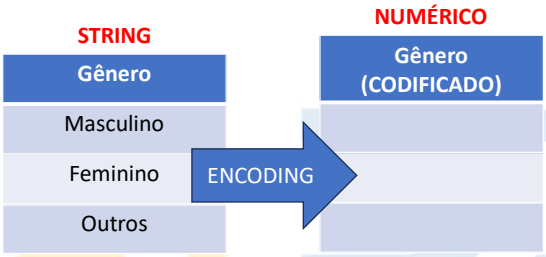


**VOCÊ PODE PERDER A EXPLICABILIDADE DOS PROCESSOS DE TRANSFORMAÇÃO**

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).



# Outras técnicas de "encoding"

Seja um Profissional Python !

Além das técnicas mostradas anteriormente...existem outras menos utilizadas...

**1.Target Encoding**:

Nesse método, cada categoria é substituída pela média do valor de destino (target) associado a ela. É útil quando a variável categórica tem uma relação significativa com o valor que está sendo previsto.

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

# Outras técnicas de "encoding"

Seja um Profissional Python !

Além das técnicas mostradas anteriormente...existem outras menos utilizadas...

**2.Weight of Evidence (WOE) Encoding**:

Esse método é frequentemente usado em análise de risco e crédito. Ele calcula o valor do peso de evidência para cada categoria, que é uma medida da força da relação entre a categoria e a variável dependente. O WOE é então usado para substituir as categorias.

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).



# Outras técnicas de "encoding"

Seja um Profissional Python !

Além das técnicas mostradas anteriormente...existem outras menos utilizadas...

**3.Hash Encoding**:

Nesse método, as categorias são convertidas em valores hash, que são sequências de caracteres alfanuméricos únicos. É útil quando há muitas categorias únicas e a dimensionalidade precisa ser reduzida.

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

## Outras técnicas de "encoding"

Seja um Profissional Python !

Além das técnicas mostradas anteriormente...existem outras menos utilizadas...

**4.Entity Embedding**:

Esse método é frequentemente usado em problemas de aprendizado de máquina com dados categóricos de alta cardinalidade. Ele mapeia cada categoria para um vetor de números reais de baixa dimensionalidade, aprendido por um modelo durante o treinamento. Isso captura as relações não lineares entre as categorias.

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).



## Outras técnicas de "encoding"

Seja um Profissional Python !

Além das técnicas mostradas anteriormente...existem outras menos utilizadas...

**5. Leave-One-Out Encoding**:

Nesse método, cada categoria é substituída pela média do valor de destino (target) associado a ela, excluindo a observação atual. Esse método pode ajudar a evitar vazamento de informações do conjunto de treinamento para o conjunto de teste em problemas de aprendizado de máquina.

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

## Outras técnicas de “encoding”

Seja um Profissional Python !

Além das técnicas mostradas anteriormente...existem outras menos utilizadas...

**6. CatBoost Encoding**:

Essa é uma técnica específica para o algoritmo CatBoost, que combina o Target Encoding com uma regularização adicional para evitar overfitting. Ele calcula a média do valor de destino para cada categoria, mas com uma correção especial para melhorar a generalização do modelo.

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).



## Outras técnicas de “encoding”

Seja um Profissional Python !

Além das técnicas mostradas anteriormente...existem outras menos utilizadas...

**7. Effect Encoding**:

Também conhecido como "deviation encoding" ou "sum encoding", esse método codifica as categorias como a diferença entre a média do valor de destino e a média geral do valor de destino. É útil quando se deseja comparar categorias em relação a uma linha de base comum.

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).

# Outras técnicas de "encoding"

Seja um Profissional Python !

Além das técnicas mostradas anteriormente...existem outras menos utilizadas...

**8. Backward Difference Encoding**:

Nesse método, cada categoria é substituída pela diferença entre a média do valor de destino da categoria e a média do valor de destino da categoria anterior. É útil quando se deseja capturar tendências sequenciais ou quando há uma ordem implícita entre as categorias.

**Entre outras....**

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).



# Técnicas de "encoding"

Seja um Profissional Python !

Vamos praticar...

**3 Mini-Projetos para trabalharmos:**

- **Count/Frequency Encoding**
- **Label Encoding**
- **One-Hot Encoding**

© Todos os Direitos reservados para Dilermando Piva Jr. (2022).